Bölüm 4

Sözcüksel(Lexical) ve Sentaks Analiz

Programming Languages



SEVENTH EDITION

Robert W. Sebesta

Bölüm 4 Konular

- 1. Giriş
- 2. Sözcüksel Analiz(Lexical Analysis)
- 3. Ayrıştırma(Parsing) Problemi
- 4. Özyineli-azalan Ayrıştırma (Recursive-Descent Parsing)
- 5. Aşağıdan-yukarıya Ayrıştırma (Bottom-Up Parsing)

4.1 Giriş

 Dil(language) implementasyon sistemleri, belirli(specific) implementasyon yaklaşımına aldırmadan kaynak kodu(source code) analiz etmelidir

 Hemen hemen bütün sentaks analizi kaynak(source) dilin sentaksının biçimsel tanımlamasına(formal description) dayalıdır (BNF)

4.1 Giriş (Devamı)

- Bir dil işlemcisinin (language processor) sentaks(syntax) analizi bölümü genellikle iki kısımdan oluşur:
 - Bir düşük-düzeyli(low-level) kısım, sözcüksel analizci (lexical analyzer) (matematiksel olarak, kurallı bir gramere(regular grammar) dayalı bir sonlu otomasyon(finite automaton))
 - Bir yüksek-düzeyli(high-level) kısım, sentaks analizci(syntax analyzer), veya ayrıştırıcı(parser) (matematiksel olarak, bağlam duyarsız gramere(contextfree grammar) dayalı bir aşağı-itme otomasyonu(pushdown automaton), veya BNF)

4.1 Giriş (Devamı)

- Sentaksı(syntax) tanımlamak için BNF kullanmanın nedenleri :
 - Net ve özlü bir sentaks tanımı(syntax description) sağlar
 - Ayrıştırıcı(parser) doğrudan BNF ye dayalı olabilir
 - BNF ye dayalı ayrıştırıcıların(parsers) bakımı daha kolaydır

4.1 Giriş (Devamı)

- Sözcüksel(lexical) ve sentaks(syntax) analizini ayırmanın nedenleri:
 - Basitlik(Simplicity) sözcüksel analiz (lexical analysis) için daha az karmaşık yaklaşımlar kullanılabilir; bunları ayırmak ayrıştırıcıyı(parser) basitleştirir
 - Verimlilik(Efficiency) ayırmak sözcüksel analizcinin(lexical analyzer) optimizasyonuna imkan verir
 - Taşınabilirlik(Portability) sözcüksel analizcinin(lexical analyzer) bölümleri taşınabilir olmayabilir, fakat ayrıştırıcı(parser) her zaman taşınabilirdir

4.2 Sözcüksel(Lexical) Analiz

- Sözcüksel analizci (lexical analyzer), karakter stringleri (character strings) için desen eşleştiricidir(pattern matcher)
- Sözcüksel analizci ayrıştırıcı(parser) için bir "önuç"tur ("front-end")
- Kaynak programın(source program) birbirine ait olan altstringlerini(substrings) tanımlar –
 - Lexemeler, jeton() adı verilen sözcüksel(lexical) bir kategoriyle ilişkilendirilmiş olan bir karakter desenini eşleştirir
 - sum bir lexemedir; jetonu(token) IDENT olabilir

- Sözcüksel analizci(lexical analyzer), genellikle ayrıştırıcının sonraki jetona(token) ihtiyaç duyduğunda çağırdığı fonksiyondur. Sözcüksel analizci(lexical analyzer) oluşturmaya üç yaklaşım:
 - Jetonların biçimsel tanımı(formal description) yazılır ve bu tanıma göre tablo-sürümlü(table-driven) sözcüksel analizciyi oluşturan yazılım aracı(software tool) kullanılır
 - Jetonları(tokens) tanımlayan bir durum diyagramı(state diagram) tasarlanır ve durum diyagramını implement eden bir program yazılır
 - Jetonları(tokens) tanımlayan bir durum diyagramı(state diagram) tasarlanır ve el ile durum diyagramının(state diagram) tablo-sürümlü(table-driven) bir implementasyonu yapılır
- Sadece ikinci yaklaşımdan bahsedeceğiz


- Durum diyagramı(State diagram) tasarımı:
 - Saf(Naive) bir durum diyagramı(state diagram) kaynak(source) dildeki her karakterde her durumdan(state) bir geçişe(transition) sahip olacaktı – böyle bir diyagram çok büyük olurdu!

- Çoğu kez, durum diyagramı basitleştirmek için geçişler(transitions) birleştirilebilir
 - Bir tanıtıcıyı(identifier) tanırken, bütün büyük (uppercase) ve küçük(lowercase) harfler eşittir
 - Bütün harfleri içeren bir karakter sınıfı(character class) kullanılır
 - Bir sabit tamsayıyı (integer literal) tanırken,
 bütün rakamlar(digits) eşittir bir rakam
 sınıfı(digit class) kullanılır

- Özgül sözcükler(reserved words) ve tanıtıcılar(identifiers) birlikte tanınabilir (her bir özgül sözcük(reserved word) için programın bir parçasını almak yerine)
 - Olası bir tanıtıcının(identifier) aslında özgül sözcük(reserved word) olup olmadığına karar vermek için tabloya başvurma(table lookup) kullanılır

- Kullanışlı yardımcı altprogramlar (utility subprograms):
 - getChar girdinin(input) sonraki karakterini alır, bunu nextChar içine koyar, sınıfını (class) belirler ve sınıfı(class) charClass içine koyar
 - addChar nextChar dan gelen karakteri
 lexemenin biriktirildiği yere koyar, lexeme
 - arama(lookup) lexeme deki stringin özgül sözcük(reserved word) olup olmadığını belirler (bir kod döndürür)

Durum Diyagramı(State Diagram)



implementasyon (başlatma(initialization) varsayalım): int lex() { getChar(); switch (charClass) { case LETTER: addChar(); getChar(); while (charClass == LETTER || charClass == DIGIT) addChar(); getChar(); return lookup(lexeme); break;

```
case DIGIT:
      addChar();
      getChar();
      while (charClass == DIGIT) {
        addChar();
        getChar();
      return INT LIT;
      break;
    /* switch'in sonu */
} /* lex fonksiyonunun sonu */
```

4.3 Ayrıştırma(Parsing) Problemi

- Ayrıştırıcının amaçları, bir girdi(input) programı verildiğinde :
 - Bütün sentaks hatalarını(syntax errors) bulur; her birisi için, uygun bir tanılayıcı(diagnostic) mesaj üretir, ve hemen eski haline döndürür (recover)
 - Ayrıştırma ağacını(parse tree) üretir, veya en azından program için ayrıştırma ağacının izini(dökümünü)(trace) üretir

4.3 Ayrıştırma(Parsing) Problemi (Devamı)

- Ayrıştırıcıların(parser) iki kategorisi:
 - Aşağıdan-yukarıya(Top down) ayrıştırma ağacını(parse tree) kökten(root) başlayarak oluşturur
 - · Sıra, ensol türevindir (leftmost derivation)
 - Ayrıştırma ağacını(parse tree) preorderda izler veya oluşturur
 - Yukarıdan-aşağıya(Bottom up) ayrıştırma ağacını(parse tree), yapraklardan(leaves) başlayarak oluşturur
 - · Sıra, ensağ türevin (rightmost derivation) tersidir
- Ayrıştırıcılar(parser) girdide(input) sadece bir jeton(token) ileriye bakar

4.3 Ayrıştırma(Parsing) Problemi (Devamı)

- Yukarıdan-aşağıya ayrıştırıcılar(Top-down parsers)
 - Bir xAa sağ cümlesel formu (right sentential form)
 verildiğinde, ayrıştırıcı(parser), sadece A nın ürettiği ilk
 jetonu(token) kullanarak, ensol türevdeki(leftmost derivation)
 sonraki cümlesel formu(sentential form) elde etmek için
 doğru olan A-kuralını(A-rule) seçmelidir
- En yaygın yukarıdan-aşağıya ayrıştırma (top-down parsing) algoritmaları:
 - Özyineli azalan(recursive-descent)- kodlanmış bir implementasyon
 - LL ayrıştırıcılar(parser) tablo sürümlü(table driven)implementasyon

4.3 Ayrıştırma(Parsing) Problemi (Devamı)

- Aşağıdan-yukarıya ayrıştırıcılar(bottom-up parsers)
 - Bir α sağ cümlesel formu(right sentential form) verildiğinde, α nın sağ türevde önceki cümlesel formu(sentential form) üretmesi için azaltılması gerekli olan, gramerde kuralın sağ tarafınd(right-hand side) olan altstringinin(substring) ne olduğuna karar verir (determine what substring of alfa is the right-hand side of the rule in the grammar that must be reduced to produce the previous sentential form in the right derivation)
 - En yaygın aşağıdan-yukarıya ayrıştırma(bottom-up parsing) algoritmaları LR ailesindedir

4.3 Ayrıştırma(Parsing) Problemi (Devamı)

- Ayrıştırmanın Karmaşıklığı(Complexity of Parsing)
 - Herhangi bir belirsiz-olmayan gramer(unambiguous grammar) için çalışan ayrıştırıcılar(parsers) karmaşık(complex) ve belirsizdir(inefficient) (O(n³), n girdinin(input) uzunluğu(length) olmak üzere)
 - Derleyiciler(compilers), sadece bütün belirsiz-olmayan gramerlerin(unambiguous grammars) bir altkümesi(subset) için çalışan ayrıştırıcıları(parser) kullanır, fakat bunu lineer sürede(linear time) yapar (O(n), n girdinin(input) uzunluğu(length) olmak üzere)

- Özyineli-azalan işlem(Recursive-descent Process)
 - Gramerde(grammar) her bir nonterminal için o nonterminal tarafından üretilebilen cümleleri(sentences) ayrıştırabilen(parse) bir altprogram(subprogram) vardır
 - EBNF, özyineli-azalan ayrıştırıcıya (recursivedescent parser) temel oluşturmak için idealdir, çünkü EBNF nonterminal sayısını minimize eder

Basit deyimler(expressions) için bir gramer(grammar) :

```
<expr> → <term> { (+ | -) <term>}
<term> → <factor> { (* | /) <factor>}
<factor> → id | ( <expr> )
```

- Lex isimli, sonraki jeton(token) kodunu nextToken içine koyan bir anlamsal analizci(lexical analyzer) olduğunu varsayalım
- Sadece bir sağdaki kısım(RHS) olduğunda kodlama işlemi:
 - Sağdaki kısımda(RHS) olan her bir terminal sembol(symbol) için, onu bir sonraki girdi jetonuyla(token) karşılaştır; eğer eşleşiyorsa, devam et, değilse hata(error) vardır
 - Sağdaki kısımda(RHS) her bir nonterminal sembol(symbol) için, onunla ilgili ayrıştırıcı alt programını(parsing subprogram) çağırır

```
/* expr fonksiyonu
   Dilde kural (rule) tarafindan üretilen
  stringleri ayristirir (parses):
    \langle expr \rangle \rightarrow \langle term \rangle \{ (+ | -) \langle term \rangle \}
 */
void expr() {
/* Ilk terimi(first term) ayristir(parse)*/
 term();
```

- Bu özel rutin hataları(errors) bulmaz
- Kural: Her ayrıştırma rutini(parsing routine) sonraki jetonu(next token) nextToken 'da bırakır

- Birden fazla sağdaki kısmı(RHS) olan bir nonterminal, hangi sağdaki kısmı(RHS) ayrıştıracağına(parse) karar vermek için bir başlangıç işlemine(initial process) gerek duyar
 - Doğru sağdaki kısım(RHS), girdinin(input) sonraki jetonunu(token) temel alarak seçilir (lookahead)
 - Bir eşlenik bulana kadar sonraki jeton(next token) her bir sağdaki kısım(RHS) tarafından üretilebilen ilk jetonla(first token) karşılaştırılır
 - Eğer eşlenik bulunmazsa, bu bir sentaks hatasıdır (syntax error)

```
/* factor fonksiyonu dilde şu kuralın(rule)
 ürettiği stringleri ayrıştırır (parse):
  <factor> -> id | (<expr>) */
void factor() {
 /* Hangi RHS oldugunu belirle*/
  if (nextToken) == ID CODE)
 /* RHS id si için, lex 'i çagir*/
   lex();
```

```
/* Eğer sagdaki kısım(RHS)(<expr>) ise - sol
  parantezi ihmal ederek lex 'i çagır, expr 'yi
  çagır, ve sag parantezi kontrol et */
  else if (nextToken == LEFT PAREN CODE) {
   lex();
    expr();
    if (nextToken == RIGHT PAREN CODE)
       lex();
    else
     error();
   } /* End of else if (nextToken == ... */
  else error(); /* Hiçbir RHS eşleşmedi*/
```

- LL Gramer Sınıfı (LL Grammar Class)
 - Sol Özyineleme(Left Recursion) Problemi
 - Eğer bir gramerin(grammar) sol özyinelemesi(left recursion) varsa, doğrudan(direct) veya dolaylı(indirect), yukarıdan-aşağıya(Top-down) ayrıştırıcının(parser) temeli olamaz
 - Bir gramer(grammar) sol özyinelemeyi(left recursion) yoketmek için değiştirilebilir

- Yukarıdan-aşağıya ayrıştırmaya(top-down parsing) izin vermeyen gramerlerin diğer bir özelliği pairwise disjointness(çiftli ayrıklık) eksikliğidir
 - Doğru olan sağ kısmı(RHS) lookaheadın bir jetonuna(token) dayanarak belirleyememesi
 - Def: FIRST(α) = {a | α =>* a β } (Eğer α =>* ϵ ise, ϵ FIRST(α) içindedir)

Pairwise Disjointness Testi:

- Her bir nonterminal A için, birden fazla sağ kısmı(RHS) olan gramerde(grammar), her bir kural(rule) çifti A $\rightarrow \alpha_i$ ve A $\rightarrow \alpha_j$ için, şu doğru olmalıdır:

$$FIRST(\alpha_i) FIRST(\alpha_j) = \phi$$

Örnekler:

$$A \rightarrow a \mid bB \mid cAb$$

 $A \rightarrow a \mid aB$

- Sol çarpan alma(Left factoring) problemi çözebilir Şu ifadeyi:
- <variable> → identifier | identifier [<expression>] aşağıdakilerden biriyle değiştirin:
- <variable> → identifier <new>
- <new $> \rightarrow \epsilon \mid [<$ expression>]veya
- <variable> → identifier [[<expression>]]
 (dıştaki köşeli parantezler EBNF 'nin
 metasembolleridir(metasymbols))

 Ayrıştırma(parsing) problemi bir sağcümlesel formda(right-sentential form) türevde önceki sağ-cümlesel(rightsentential) formu elde etmek için azaltılacak doğru sağ kısmı(RHS) bulmaktır

- ·İşleyiciler(tanıtıcı değer)(handles) hakkında:
 - Tanım: β , sağ cümlesel formun(right sentential form) işleyicisidir(tanıtıcı değeridir)(handle)

 $\gamma = \alpha \beta w$ ancak ve ancak (if and only if)

$$S = > *rm \alpha Aw = >rm \alpha \beta w$$

Tanım: β , sağ cümlesel formun(right sentential form) tümceciğidir(phrase)

γ ancak ve ancak(if and only if)

$$S = > * \gamma = \alpha_1 A \alpha_2 = > + \alpha_1 \beta \alpha_2$$

- Tanım: β , sağ cümlesel form(right sentential form) γ nın basit tümceciğidir (simple phrase) ancak ve ancak(if and only if)

$$\underset{\text{Copyright @ 2006 Pearson Addison-Wesley. All rights reserved.}}{\text{S}} = > \underset{\text{Copyright } \text{@ 2006 Pearson Addison-Wesley. All rights reserved.}}{\text{All rights reserved.}} \alpha_1 \beta \alpha_2$$

- İşleyiciler(tanıtıcı değer)(handles) hakkında :
 - Bir sağ cümlesel formun(right sentential form)
 işleyicisi(handle) onun en soldaki(leftmost) basit
 tümceciğidir(simple phrase)
 - Verilen bir ayrıştırma ağacında(parse tree), şimdi işleyiciyi(handle) bulmak kolaydır
 - Ayrıştırma(parsing) , işleyici budama(handle pruning) olarak düşünülebilir

- Kaydırma-İndirgeme Algoritmaları(Shift-Reduce Algorithms)
 - İndirgeme(Reduce), ayrıştırma yığınının(parse stack) üstündeki işleyici(handle) ile ona ilişkin LHS nin yerini değiştirme işlemidir
 - Kaydırma(Shift), bir sonraki jetonu(next token) ayrıştırma yığınının(parse stack) üstüne koyma işlemidir

- LR ayrıştırıcıların(LR parsers) avantajları:
 - Programlama dillerini tanımlayan gramerlerin hemen hemen tümü için çalışır.
 - Diğer aşağıdan-yukarıya algoritmalardan (bottom-up algorithms) daha geniş bir gramerler sınıfı için çalışır, fakat diğer aşağıdan-yukarıya ayrıştırıcıların(bottom-up parser) herhangi biri kadar da verimlidir
 - Mümkün olan en kısa zamanda sentaks hatalarını(syntax errors) saptayabilir
 - LR gramerler sınıfı(LR class of grammars), LL ayrıştırıcıları (LL parsers) tarafından ayrıştırılabilen sınıfın(class) üstkümesidir(superset)


- LR ayrıştırıcıları(parsers) bir araç(tool) ile oluşturulmalıdır
- Knuth'un görüşü(Knuth's insight): Bir aşağıdan-yukarıya ayrıştırıcı(bottom-up parser), ayrıştırma(parsing) kararları almak için, ayrıştırmanın o ana kadar olan bütün geçmişini(history) kullanabilirdi
 - Sonlu ve nispeten az sayıda farklı ayrıştırma durumu oluşabilirdi, bu yüzden geçmiş(history) ayrıştırma yığını(parse stack) üzerinde bir ayrıştırıcı durumunda(parser state) saklanabilirdi

 Bir LR yapılandırması(configuration) bir LR ayrıştırıcının(LR parser) durumunu(state) saklar

• (S0X1S1X2S2...XmSm, aiai+1...an\$)

- LR ayrıştırıcılar(LR parsers) tablo sürümlüdür(table driven),bu tablonun iki bileşeni vardır, bir ACTION tablosu ve bir GOTO tablosu
 - ACTION tablosu, verilen bir ayrıştırıcı durumu(parser state) ve sonraki jeton(next token) için, ayrıştırıcının(parser) hareketini(action) belirler
 - Satırlar(rows) durum(state) adlarıdır; sütunlar(columns) terminallerdir
 - The GOTO tablosu bir indirgeme hareketi(reduction action) yapıldıktan sonra ayrıştırma yığını(parse stack) üzerine hangi durumun(state) konulacağını belirler
 - Satırlar(rows) durum(state) adlarıdır; sütunlar(columns) nonterminallerdir

Bir LR Ayrıştırıcısının(Parser) Yapısı



- Başlangıç yapılandırması: (S₀, a₁...a_n\$)
- Ayrıştırıcı hareketleri(parser actions):
 - If ACTION[S_m , a_i] = Shift S, sonraki yapılandırma: ($S_0X_1S_1X_2S_2...X_mS_ma_iS$, $a_{i+1}...a_n$ \$)
 - If ACTION[S_m , a_i] = Reduce A $\rightarrow \beta$ and S = GOTO[S_{m-r} , A], $r = \beta$ nın uzunluğu olmak üzere , sonraki yapılandırma:

$$(S_0X_1S_1X_2S_2...X_{m-r}S_{m-r}AS, a_ia_{i+1}...a_n)$$

- Ayrıştırıcı hareketleri(parser actions) (devamı):
 - If ACTION[Sm, ai] = Accept, ayrıştırma(parse)
 tamamlanmıştır ve hata(error) bulunmamıştır
 - If ACTION[Sm, ai] = Error, ayrıştırıcı(ayrıştırıcı)
 bir hata-işleme rutini(error-handling routine)
 çağırır

LR Ayrıştırma Tablosu(Parsing Table)

	Action						Goto		
State	id	+	*	()	\$	E	Т	F
0	S 5		S4				1	2	3
1		S6				accept			
2		R2	S7		R2	R2			
3		R4	R4		R4	R4			
4	S5			S4			8	2	3
5		R6	R6		R6	R6			
6	S5			S4				9	3
7	S5			S4					10
8		S6			S11				
9		R1	S7		R1	R1			
10		R3	R3		R3	R3			
11		R5	R5		R5	R5			

 Verilen bir gramerden(grammar) bir araç (tool) ile bir ayrıştırıcı tablosu(parser table) üretilebilir, örn., yacc

Özet

- Sentaks analizi(Syntax analysis) dil implementasyonunun ortak kısmıdır
- Bir sözcüksel analizci(lexical analyzer) bir programın küçük-ölçekli parçalarını ayıran bir desen eşleştiricidir(pattern matcher)
 - Sentaks hatalarını(syntax errors) saptar
 - Bir ayrıştırma ağacı(parse tree) üretir
- Bir özyineli-iniş ayrıştırıcı(recursive-descent parser) bir LL ayrıştırıcıdır(LL parser)
 - EBNF
- Aşağıdan-yukarıya ayrıştırıcıların(bottom-up parsers) ayrıştırma problemi: o anki cümlesel formun altstringini(substring) bulma
- LR ailesi kaydırma-indirgeme ayrıştırıcıları(shiftreduce parsers) en yaygın olan aşağıdan-yukarıya ayrıştırma (bottom-up parsing) yaklaşımıdır